



FGV EESP ripple

IME  
USP

# QUANTIFICANDO O RISCO DEFI VS RWA: MODELAGEM E PREVISÃO DO SPREAD ON-CHAIN

- Renzo Filho   Felipe Caram   Lucas Martins   Caio Vieira   Bernardo Pereira



out-of-sample

# INTRODUÇÃO

## CONTEXTUALIZAÇÃO

O mercado de Real World Assets (RWA) representa a próxima fronteira da integração entre o sistema financeiro tradicional (TradFi) e as finanças descentralizadas (DeFi), sinalizando uma transição para uma "economia tokenizada" global. As previsões de mercado consolidam essa visão, com o Boston Consulting Group (BCG) estimando um mercado de US\$ 16,1 trilhões até 2030 e o Citi projetando de US\$ 4 a US\$ 5 trilhões apenas em títulos tokenizados.

Em contexto nacional, o Brasil, em particular, está se posicionando como um hub de tokenização na América Latina. O país possui um ecossistema pioneiro, impulsionado por uma digitalização massiva (via Pix e a alta adoção do gov.br) e um ambiente regulatório proativo.

O Drex, a Moeda Digital oficial de Banco Central (CBDC) do Brasil, está no centro dessa transformação. Sendo mais do que um sistema de pagamento, o Drex é uma plataforma tecnológica (DLT, similar ao blockchain) criada pelo Banco Central para possibilitar novos tipos de negócios e dinheiro programável.

Dentro do Drex, a tokenização é de extrema relevância, a fase 2 do Piloto Drex teve enfoque em tokenizar diversos investimentos reais, como Títulos Públicos, Debêntures, Cédulas de Crédito Bancário (CCBs) e ativos do agronegócio. O objetivo é criar uma alternativa oficial e regulada às stablecoins para permitir a negociação segura dessa nova renda fixa digital.

Essa convergência cria dois tipos fundamentalmente diferentes de rendimento competindo no mesmo ambiente on-chain:

- O Rendimento TradFi/RWA: Derivado de ativos do mundo real, como os Títulos Públicos testados no Drex ou a taxa SOFR (o benchmark "livre de risco" do nosso modelo).
- O Rendimento DeFi Nativo: Gerado algorítmicamente por protocolos como Aave e Compound. Este rendimento não vem de um ativo real, mas da pura demanda por alavancagem on-chain.

## O PROBLEMA:

Quais fatores explicam o spread de rendimento pago por protocolo Aave e Compound para um depósito em USDC, em comparação com a taxa de juros "livre de risco" (SOFR) do dólar no sistema financeiro tradicional tokenizado?

## HIPÓTESE:

O spread de juros observado não é aleatório. Ele funciona como um "indicador de risco" do ecossistema DeFi, e seus principais determinantes podem ser modelados por uma combinação de fatores on-chain e off-chain.

## MODELAGEM:

**Target (Y):** Spread de Risco = Yield Ponderado de DeFi (Aave/Compound) - Yield de TradFi tokenizado (RWA / Livre de Risco)

$$Y_{DeFi} - Y_{TradFi}$$

onde o Yield de DeFi representa o APY de depósitos em stablecoin (USDC) em protocolos de liquidez (Aave V3 e Compound V3), e o Yield de TradFi é a taxa SOFR (Secured Overnight Financing Rate), o benchmark global livre de risco derivado dos títulos do tesouro dos EUA, que será usado como proxy do rendimento do RWA T-bills.

**Features (X):** Fatores de risco on-chain e off-chain

O valor desse spread representará o prêmio que os investidores exigem para alojar capital em protocolos DeFi, em vez de manter um ativo TradFi equivalente em forma tokenizada.

# OS PROTOCOLOS DEFI

## O MODELO DE POOL DE LIQUIDEZ

O Modelo de Pool de Liquidez (Peer-to-Pool) Diferente de bancos tradicionais (Peer-to-Bank) ou empréstimos diretos (Peer-to-Peer), estes protocolos utilizam Smart Contracts para criar pools de ativos. Depositantes fornecem liquidez em troca de juros passivos, e tomadores retiram liquidez pagando juros ativos mediante garantia (colateral).

## A DINÂMICA DO APY (ANNUAL PERCENTAGE YIELD)

A taxa de juros não é definida pelo protocolo, mas pelo mercado (Oferta vs. Demanda), seguindo a seguinte fórmula:

$$APY_{Supply} = APY_{Borrow} \times U_t \times (1 - Fator\_Reserva)$$

Onde  $U_t$  é a utilização, ou seja, a porcentagem da pool que está emprestada e o Fator Reserva é a porcentagem de juros que o protocolo retém para si.

## AAVE V3 PROTOCOL

### Mecânica do token

Ao depositar 100 USDC se recebe 100 aUSDC.

O rendimento ocorre automaticamente com o saldo aumentando a cada bloco.

### Diferenciais

- Flash Loans: empréstimos instantâneos sem colateral, para arbitragem.
- Rate Switching: permite que o tomador alterne entre taxa variável e estável.



## COMO FUNCIONA A ALAVANCAGEM

Possibilita a multiplicação de exposição a um ativo sem capital externo, como segue no exemplo:

- Depósito: Usuário deposita \$1.000 em ETH como colateral.
- Empréstimo: Com base no LTV (Loan-to-Value) de 80%, toma \$800 em USDC emprestado.
- Swap & Re-Depósito: Troca os USDC por mais ETH e deposita novamente no protocolo.
- Resultado: O usuário agora rende juros sobre \$1.800 de ETH (e não apenas \$1.000), subtraindo o custo do juro do empréstimo em USDC.

Risco: se o valor do colateral cair a um nível crítico, será acionada a liquidação automática, forçando a venda do ativo para pagar a dívida.

## COMPOUND V3 PROTOCOL

### Mecânica do token

Ao depositar 100 USDC se recebe a quantidade de cUSDC correspondente ao câmbio do momento.

O rendimento ocorre pela taxa de câmbio, a quantidade de cUSDC se mantém estável mas o valor deles em USDC sobe com o tempo.

### Diferenciais

- Simplicidade: foco em menos ativos, mais seguros e líquidos.
- Modelo COMP: governança descentralizada com incentivos via token nativo.



# METODOLOGIA E DADOS

## ESCOLHA DO TARGET

No slide anterior, apresentamos nossa variável alvo. Ela é composta por três fatores cruciais para o escopo do projeto.

Para representar o rendimento DeFi, utilizamos os dois maiores mercados monetários algorítmicos da rede Ethereum: **Aave V3** e **Compound V3**. Calculamos um *yield* unificado do APY de ambos, ponderando pelo Valor Total Bloqueado (TVL) de cada protocolo.

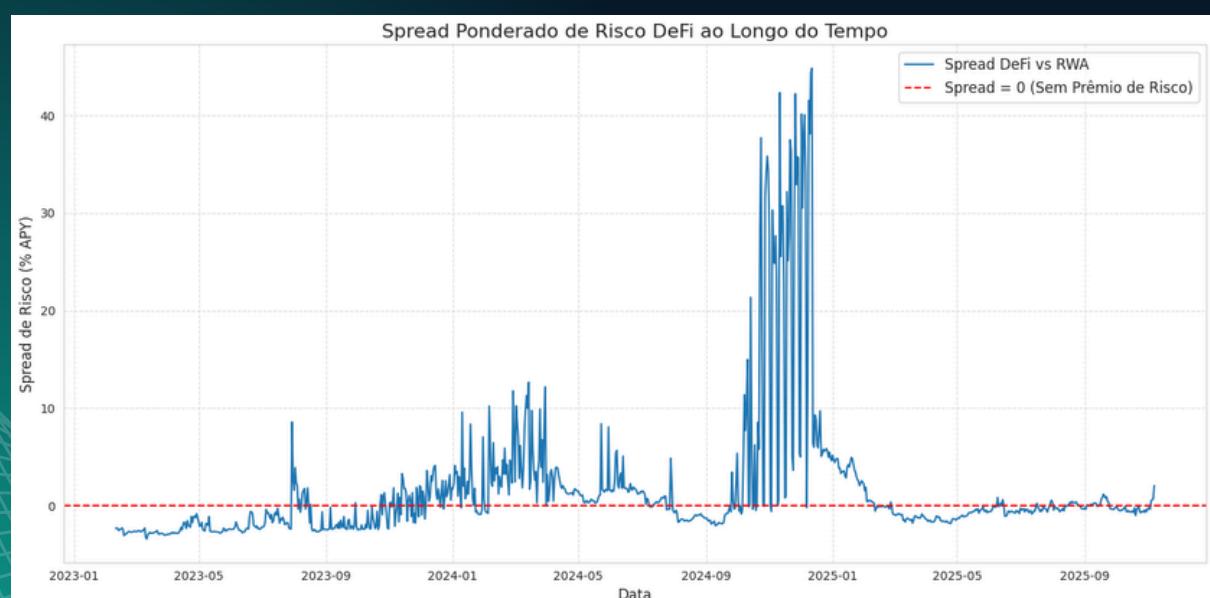
$$Y_{DeFi} = \frac{(APY_{aave} \times TVL_{aave}) + (APY_{compound} \times TVL_{compound})}{TVL_{total}}$$

Tais protocolos permitem que utilizadores forneçam liquidez para ganhar juros ou contraiam empréstimos colocando criptoativos como garantia, sem a necessidade de um intermediário tradicional como um banco.

Como benchmark livre de risco, utilizamos a taxa SOFR (Secured Overnight Financing Rate). Esta é a taxa de referência para empréstimos overnight (diários) em dólar, garantidos por Títulos do Tesouro dos EUA

$$Y_{TradFi} = SOFR$$

Portanto, o target final será a diferença entre esses dois componentes.



## ENGENHARIA DE FEATURES

Para explicar e prever as flutuações do spread, dividimos as features em três categoriais:

### Fatores On-Chain:

- Taxas de utilização dos pools de Aave e Compound
- Preço do Gás (custo de transação) na rede Ethereum
- Risco de Depeg (perda de paridade) da stablecoin USDC
- Variação do TVL total (fluxo de capital DeFi)

### Fatores de Mercado (Macro e Cripto):

- Volatilidade do VIX (o "índice do medo" de TradFi)
- Yield do Tesouro Americano (DGS2)
- Retornos e Volatilidade do ETH e BTC

### Fatores Autorregressivos:

- Valores do spread alvo em dias anteriores (lags de 1, 3 e 7 dias)

As features on-chain buscam quantificar o estresse, o custo e o sentimento interno do ecossistema DeFi. As features de mercado capturam o ambiente de risco mais amplo ("medo"), que afeta a disposição dos investidores em alocar capital em ativos de risco como os RWAs tokenizados.

## OBTENÇÃO DOS DADOS

Os dados brutos foram coletados de cinco fontes (The Graph, Dune, FRED, Etherscan e Defillama) e consolidados em um único conjunto para análise. Enquanto a maioria das informações foi obtida diretamente em arquivos CSV, os dados do The Graph e do Defillama foram acessadas por meio de consultas via API ou subgraphs.

A natureza emergente do tema impôs limitações consideráveis à disponibilidade de dados. Observou-se que uma parcela significativa das séries históricas relevantes encontrava-se sob paywalls ou apresentava cobertura temporal restrita, iniciando-se apenas em 2023.



# IDENTIFICANDO REGIMES DE MERCADO

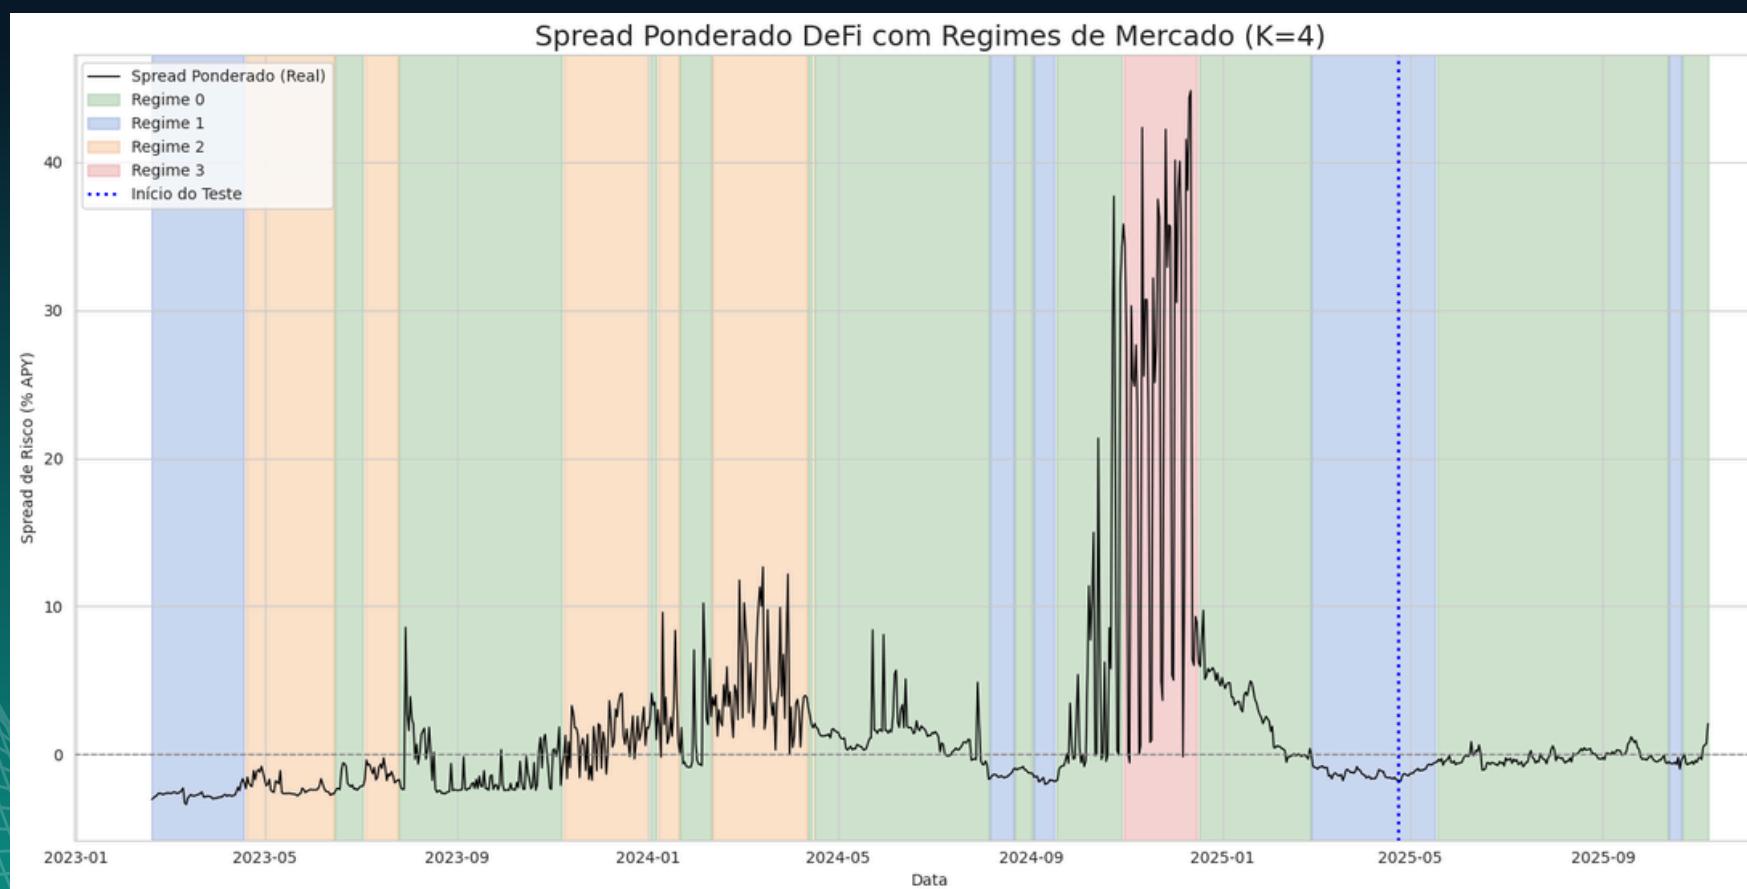
## ABORDAGENS

Para testar nossa hipótese, desenvolvemos duas abordagens para prever o spread DeFi-TradFi. A primeira tentará utilizar modelos clássicos e *clusters* para tentar identificar regimes de mercado. Enquanto isso, a segunda utilizará modelos de deep learning consolidados na área para capturar a dinâmica temporal.

## CLUSTERIZAÇÃO DOS DADOS

Nessa primeira etapa, buscamos padrões nos dados capazes de indicar comportamentos do mercado que explicassem o spread Defi-RWA.

Para definir os regimes de mercado, utilizamos o algoritmo K-Means (com  $k=4$ , após otimização) sobre o conjunto de features. Para garantir a estabilidade dos regimes e evitar ruídos diários, aplicamos um filtro de Moda Móvel Causal (janela de 7 dias) sobre os labels de cluster resultantes. Isso assegura que o modelo só mude de regime após uma tendência consolidada.



## INTERPRETAÇÃO DOS CLUSTERS

**REGIME 0 (verde):** Este regime mostra que o estado normal para o mercado DeFi é um de alta demanda por alavancagem (utilização em 88%), coexistindo com um nervosismo de fundo nos mercados (VIX em 15.5). O spread é baixo porque o cenário é suficientemente ativo para gerar retornos atraentes, mas não excessivamente especulativo a ponto de gerar distorções.

**REGIME 1 (azul):** Este é o regime de busca de segurança. O pânico nos mercados tradicionais (VIX) não causa um aumento drástico no spread DeFi. Pelo contrário, ele causa uma fuga de capital de DeFi (a utilização cai), o que faz o spread contra os RWA ficar negativo.

**REGIME 2 (amarelo):** Este é o regime de euforia on-chain. A atividade na rede (gás) está frenética e a demanda por alavancagem (utilização) está no máximo. Esse cluster é um sinal de alerta forte.

### REGIME 3 (vermelho):

Este é o regime de crise de liquidez. O sistema está superaquecido, a utilização está no máximo, o gás está caro, o VIX está alto e a própria diferença no mercado DeFi está alta (Spread Aave/Compound elevado). O spread contra RWA dispara porque a demanda por empréstimos em stablecoin supera massivamente a oferta.

	Centroides dos Clusters (Valores Z-Score)			
	0	1	2	3
X_Lag_1D	0.95	-1.82	1.03	31.92
X_Lag_3D	2.05	-1.76	1.45	18.23
X_Lag_7D	1.76	-1.59	1.10	22.43
X_Aave_Utilization_Lag1	0.86	0.68	0.88	0.98
X_USDC_Depeg_Risk_Lag1	0.30	0.33	0.37	0.36
X_VIX_Lag1	15.54	22.94	14.62	16.23
X_DGS2_Lag1	4.55	4.06	4.53	4.21
X_Gas_Price_Gwei_Lag1	15.16	15.51	44.55	21.11
X_ETH_Returns_Lag1	-0.00	-0.00	0.00	0.01
X_ETH_Vol_7D_Lag1	0.06	0.10	0.07	0.10
X_BTC_Returns_Lag1	0.00	0.00	0.00	0.01
X_BTC_Vol_7D_Lag1	0.05	0.08	0.07	0.07
X_Gas_MA_7D_Lag1	16.08	15.70	43.77	18.75
X_VIX_Pct_Change_Lag1	0.00	0.01	-0.00	-0.01
X_Compound_Utilization_Lag1	88.14	70.43	90.52	91.70
X_Spread_Aave_Compound_Lag1	0.37	-0.38	-0.33	34.11
X_Delta_TVL_DeFi_7D_pct_Lag1	0.01	0.03	0.05	0.04

# RESULTADOS

## TREINAMENTO

Como cada amostra do dataset de treino foi classificada em um dos 4 regimes, podemos aplicar vários modelos de regressão para cada *cluster* e verificar qual deles possui o melhor desempenho. O dataset foi dividido de forma 80/20, onde o conjunto de teste contém 20% dos dados mais recentes da série temporal.

## O MODELO HÍBRIDO

O Modelo final é híbrido, pois escolhe o melhor regressor em cada cluster. A definição de melhor modelo foi baseada na métrica de RMSE, isto é, o modelo que melhor minimizou o erro no treino.

Uma observação pertinente é que dois clusters, identificados no treino, não se fazem presentes no teste. Isso se dá, principalmente, pela natureza recente do problema, que carece de vastos datasets. Uma alternativa poderia ser a união de clusters, no entanto, essa abordagem ocasiona uma perda significativa de informações, bem como, um aumento drástico da variância dentro dos clusters. Logo, para uma análise mais coerente, avaliaremos apenas os resultados nos clusters 0 e 1, presentes no teste.

Fizemos testes e validações cruzadas apropriadas para dados temporais avaliando os seguintes modelos.

- Random Forest
- XGBoost
- SVM
- Regressão LASSO

Por questões de otimização de espaço, mostraremos apenas os resultados do modelo vitorioso. Para detalhes dos outros modelos, confira nosso repositório do GitHub.

## MÉTRICAS

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

## PREVISÃO

O modelo vencedor nos clusters 0 e 1 foi o SVM. Dentre todos, ele foi o que melhor generalizou os dados e o comportamento dos regimes. A seguir, seus resultados.

REGRESSOR SVM			
Cluster	RMSE	MAE	R2 Score
0	0,3429	0,2514	0,4339
1	0,2757	0,2286	0,5324
Global	0,3324	0,2475	0,6217

O  $R^2$  mede a proporção da variância do spread real que é explicada pelo nosso modelo. O nosso  $R^2$  Global de 0.6217 demonstra que a abordagem híbrida (Clusterização + SVM) foi bem-sucedida, explicando 62,17% da variação do spread nos dados de teste. Isso é bem animador, pois mostra que a aparente “aleatoriedade” dos dados pode ser explicada em cada regime.

O Erro Quadrático Médio é crucial para problemas como este, que envolvem picos e volatilidade. Ao elevar os erros ao quadrado, esta métrica penaliza erros grandes (como picos de spread não previstos) muito mais do que o MAE. O RMSE foi nossa métrica de seleção principal durante o treinamento para escolher o melhor regressor (XGBoost, RF ou SVM) para cada cluster, pois queríamos o modelo que melhor minimizasse o erro em eventos extremos.

# MODELAGEM DE RISCO

## UMA OUTRA ABORDAGEM

Os resultados desse modelo são promissores e bem informativos. Contudo, seria muito interessante aproveitar toda a extensão do dataset para obter previsões. Nesse contexto, os modelos de *deep learning* são escolhas quase que imediatas, pois são projetados para capturar relações complexas.

## SOBRE O MODELO APLICADO

Usamos o GARCH (Generalized AutoRegressive Conditional Heteroskedasticity) que é um modelo econométrico para modelar e prever a volatilidade.

Quebrando os termos que compõe o acrônimo, temos:

- Heterocedasticidade: Significa que a volatilidade do ativo não é constante ao longo do tempo. Alguns dias são calmos, outros são caóticos.
- Condicional: A volatilidade de hoje depende do que aconteceu ontem.
- Autorregressiva: A previsão da volatilidade de hoje usa valores passados da própria volatilidade.
- Generalizada: O modelo também usa os retornos passados para prever a volatilidade.

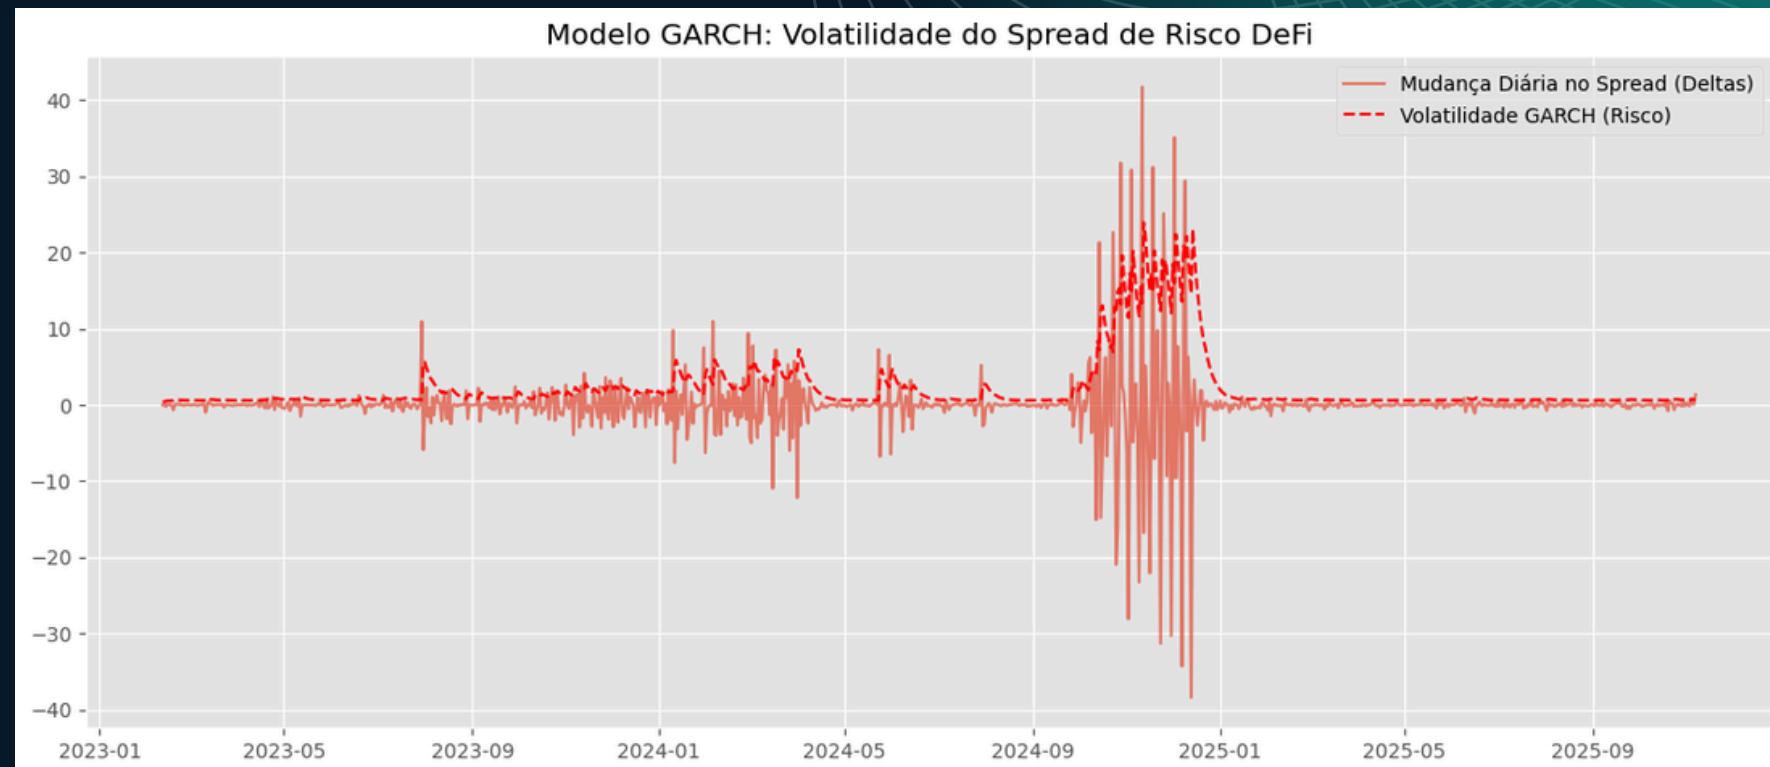
## MOTIVAÇÃO

Notamos que o delta diário no Spread era clusterizado, com períodos altamente calmos e outros muito oscilantes, isso fez com que as características intrínsecas ao GARCH fossem muito úteis ao nosso modelo, afinal este assume um risco não constante. Além disso, percebemos um bom respaldo científico para a aplicação deste modelo, a exemplo em Chu, J., Chan, S., Nadarajah, S., & Osterrieder, J. (2017). "GARCH modelling of cryptocurrencies" e Katsiampa, P. (2017). "Volatility estimation for Bitcoin: A comparison of GARCH models".

## SOBRE A APLICAÇÃO

- Input: Deltas diários do Spread de Risco DeFi.
- Configuração: GARCH(1,1) com Média Constante e Distribuição Normal.
- Bibliotecas: Python (arch), Otimização via Máxima Verossimilhança.

## RESULTADOS



alpha[1] 0.2527 4.460e-02 5.665 1.471e-08 [ 0.165, 0.349]

beta[1] 0.7473 3.800e-02 19.668 4.073e-86 [ 0.673, 0.822]

## DIAGNÓSTICO

- Reação Imediata (alfa aproximadamente 0,25): O modelo confirma alta sensibilidade a novos choques ou seja, o risco dispara em casos de choque.
- Alta Persistência (beta aproximadamente 0,75): A volatilidade permanece elevada mesmo após o choque inicial passar.
- Regime Permanente (alfa + beta aproximadamente 1): Sugere comportamento IGARCH. Os choques alteram o patamar de risco do mercado de forma duradoura, sem retorno rápido à média.

Confirmarmos isto visualmente, a exemplo no final de 2024, o risco previsto demora para cair do patamar alto, embora tendo subido rapidamente, demonstrando essa rapidez na subida e lentidão na descida.

# SOTA: TEMPORAL FUSION TRANSFORMER (TFT)

## SOBRE O MODELO APLICADO

Utilizamos o TFT (Temporal Fusion Transformer), uma arquitetura de Deep Learning considerada o estado da arte para previsão de séries temporais complexas. Quebrando os componentes principais:

- Temporal: Processa a sequência temporal utilizando LSTMs (Long Short-Term Memory) para capturar dinâmicas locais e dependências de curto prazo.
- Fusion: Integra múltiplos tipos de dados (variáveis estáticas, variáveis futuras conhecidas e variáveis históricas observadas) em uma única representação latente.
- Transformer (Attention): Utiliza mecanismos de Self-Attention para identificar quais momentos do passado (dias ou semanas atrás) são mais relevantes para a previsão atual, permitindo "memória de longo prazo" e interpretabilidade.

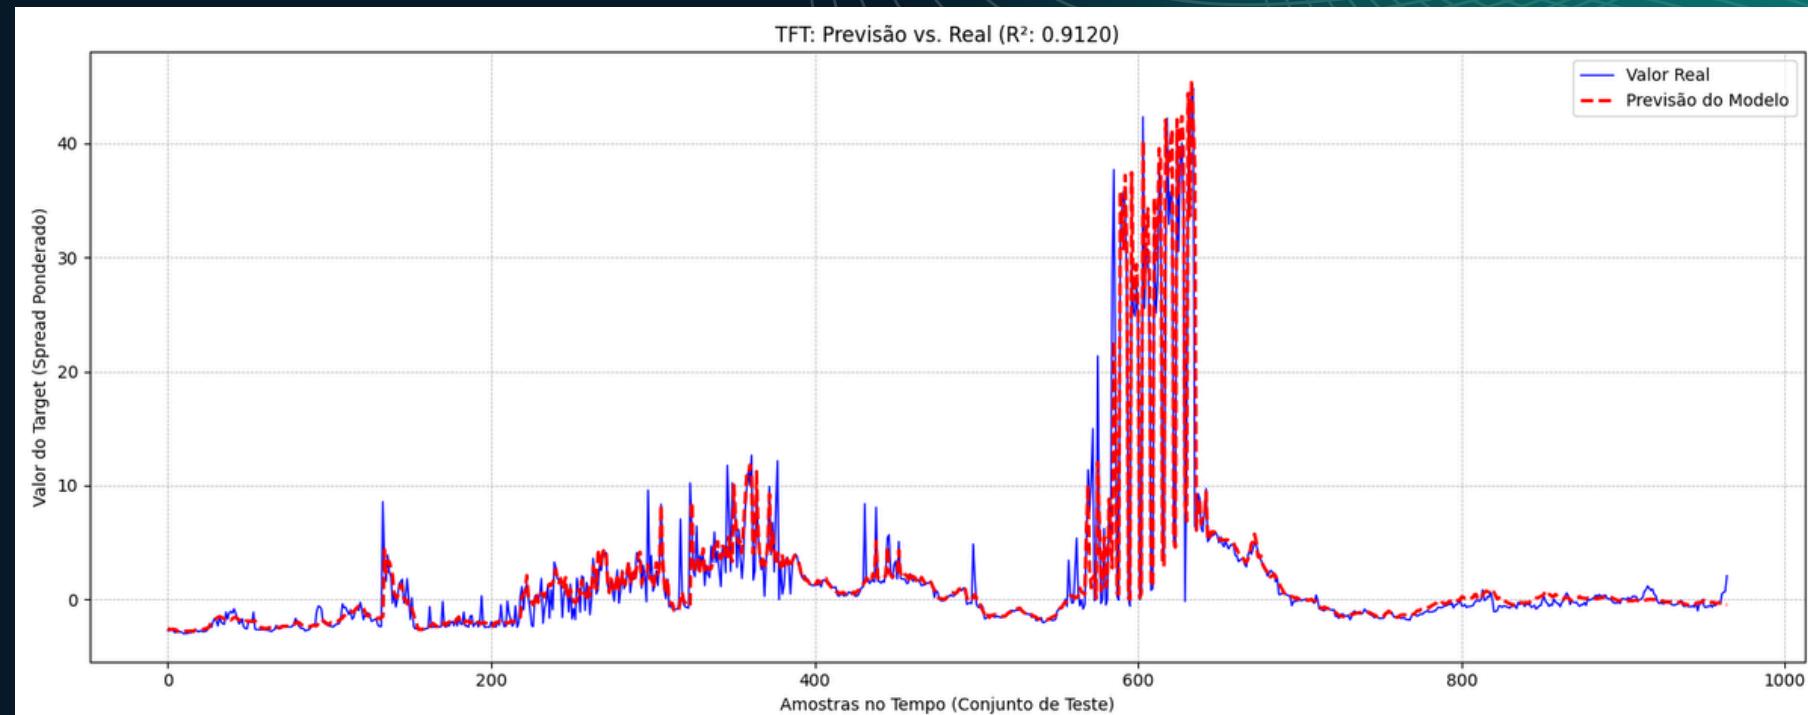
## MOTIVAÇÃO

O Spread de Risco DeFi é influenciado por uma mistura complexa de fatores macroeconômicos (VIX, Taxas de Juros) e métricas on-chain (TVL, Utilização). Modelos lineares ou puramente autorregressivos falham em capturar as mudanças abruptas de regime (picos de estresse). O TFT foi escolhido por sua capacidade de aprender relações não-lineares e pela interpretabilidade nativa via Variable Selection Networks, permitindo identificar quais variáveis pesam na decisão do modelo. Referência: Lim et al. (2021) - Google Cloud AI, que propõe o modelo como SOTA (State of The Art).

## SOBRE A APLICAÇÃO

- Input: 38 Features (Risco de Mercado, Métricas On-Chain, Volatilidades Móveis e Lags do Target).
- Configuração: Lookback de 30 dias prevendo 1 dia à frente.
- Biblioteca: PyTorch Forecasting (baseado em PyTorch Lightning), com otimização de hiperparâmetros via Learning Rate Tuner.

## RESULTADOS

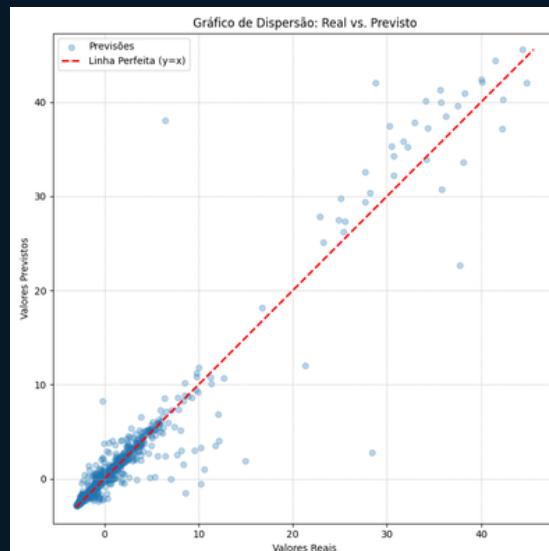


## PERFORMANCE DO MODELO NO TESTE

- R-Squared ( $R^2$ ): 0.9120 – O modelo conseguiu capturar a dinâmica de mercado.
- MAE (Erro Médio): 0.766 – Na média, o modelo erra menos de 1 porcento na previsão do spread.
- RMSE: 2.05 – Métrica tem valor razoável, mesmo considerando outliers nos períodos de alta volatilidade.

## ANÁLISE VISUAL

- Aderência Temporal: O gráfico de série temporal confirma que o TFT antecipa corretamente os regimes de estresse e picos de spread, superando modelos lineares que tendem a suavizar esses movimentos.
- Dispersão ( $y=x$ ): A forte correlação na diagonal demonstra que o modelo não possui viés sistemático, isto é, não erra consistentemente em um caso específico.



# CONCLUSÕES

Após essa série de análises, chegamos à etapa final. Nossa hipótese central foi confirmada: o spread DeFi vs. RWA não é aleatório, mas sim um "indicador de risco" do ecossistema. Nossos modelos provaram que ele é determinado por uma combinação complexa de fatores on-chain e off-chain.

Nossos modelos foram capazes de alcançar valores significativos em métricas consolidadas, além de gerar fortes insights sobre o comportamento do spread DeFi.

## PRINCIPAIS DESCOBERTAS: OS DRIVERS DO RISCO DEFI

A análise identificou quatro regimes de mercado que revelam os verdadeiros gatilhos do spread:

1. Pânico no Mercado Tradicional Não É o Causador Principal: Foi comprovado que um VIX elevado, por si só, não causa o pico de spread. Na verdade, ele provoca uma fuga de capital do ecossistema DeFi, resultando na compressão do spread.
2. O Gás é o Sinal de Alerta: Um regime específico atua como precursor da crise, caracterizado por taxas de Gás extremamente altas e Utilização da rede no limite. Este é um sinal claro de "Euforia On-Chain".
3. A Crise é de Liquidez Interna: O pico de spread ocorre quando o sistema superaquecido atinge seu limite. Neste momento, o \*\*spread interno do DeFi\*\* dispara, a demanda por capital supera massivamente a oferta e o spread contra ativos reais (RWA) explode.
4. A Volatilidade é Persistente: Foi confirmado que os choques de volatilidade no mercado DeFi são duradouros. O risco não se dissipa rapidamente após um pico, mas sim altera o patamar de risco do mercado de forma mais permanente.

## COMPARAÇÃO ENTRE OS MODELOS

A análise do projeto empregou duas abordagens de modelagem com objetivos distintos, mas complementares. De um lado, o Temporal Fusion Transformer (TFT), uma arquitetura de deep learning de "estado da arte", demonstrou um poder preditivo superior, alcançando um  $R^2$  de 0.9120 e um MAE de 0.766 no conjunto de teste. O TFT provou ser excepcional em capturar as dinâmicas temporais complexas e não-lineares, antecipando corretamente os picos de estresse e volatilidade.

Por outro lado, o Modelo Híbrido (K-Means + SVM), embora tenha apresentado um  $R^2$  Global robusto de 0.6217, teve seu valor principal na interpretabilidade. Ao classificar o mercado em quatro regimes distintos (como "Pânico TradFi" vs. "Euforia On-Chain"), esta abordagem permitiu-nos identificar os drivers fundamentais por trás das mudanças no spread, algo que o TFT, por sua natureza de "caixa-preta", não oferece. É crucial notar que o  $R^2$  do modelo híbrido foi calculado em um período de teste que não continha os regimes de crise, o que explica seu erro (MAE 0.2475 / RMSE 0.3324) ser menor. Portanto, o TFT se destaca pela precisão preditiva, enquanto o Modelo Híbrido se destaca pela inteligência de mercado e pela capacidade de gerar insights estratégicos.

## IMPLICAÇÕES E PRÓXIMOS PASSOS

O spread DeFi-RWA é um termômetro eficaz do estresse sistêmico on-chain. Modelos de risco tradicionais falham porque tratam o mercado como um ambiente homogêneo, ignorando as dinâmicas radicalmente distintas de cada regime identificado.

Outros modelos podem ser aplicados para prever a probabilidade de transitar entre estados e/ou regimes. Isso poderá permitir uma gestão de risco proativa.

Além disso, a disponibilidade de datasets públicos mais abrangentes e com dados históricos de maior profundidade é crucial. Esse tipo de dado não apenas validaria a robustez dos regimes identificados ao longo de diferentes ciclos de mercado, mas também permitiria refinar a precisão do sistema de alerta antecipado, tornando-o uma ferramenta mais confiável para a gestão de risco.

# REFERÊNCIAS BIBLIOGRÁFICAS

- Chu, J., Chan, S., Nadarajah, S., & Osterrieder, J. (2017). "GARCH modelling of cryptocurrencies".
- Katsiampa, P. (2017). "Volatility estimation for Bitcoin: A comparison of GARCH models.";
- Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). "Temporal Fusion Transformers for interpretable multi-horizon time series forecasting". (Referenciado no slide sobre TFT como Lim et al. (2021))
- Atlantico. (2025). Latin America Digital Transformation Report 2025.
- Boston Consulting Group (BCG) & ADDX. (2023). "Relevance of on-chain asset tokenization in 'crypto winter'". (Fonte da estimativa de US\$ 16,1 trilhões)
- Citi GPS. (2023, Março). "Money, Tokens, and Games: Blockchain's Next Billion Users and Trillions in Value." (Fonte da estimativa de US\$ 4-5 trilhões)
- Banco Central do Brasil. (2024, Novembro). Drex Pilot's phase 1 report is available. (Fonte sobre o "Trilema da Privacidade")
- Banco Central do Brasil. (2024, Outubro). The Future of Financial Intermediation. (Apresentação de Roberto Campos Neto detalhando os 13 casos de uso de RWA no Piloto Drex)
- Banco Central do Brasil. (n.d.). FAQ - Drex. (Define o Drex como plataforma DLT para uma economia tokenizada)
- Aave. (n.d.). Aave Protocol. (Documentação oficial)
- Compound Finance. (n.d.). Compound: The Money Market Protocol. (Whitepaper)
- MakerDAO. (n.d.). Whitepaper. (Descreve o protocolo e a integração com RWA)

Crédito ao mentor: Ao conversarmos com o orientador, David Wasserman, nos foi sugerido usar dados do protocolo MakerDAO (atual SKY), assim agregamos dados do APY de depósito e TVL no dataframe dos modelos de deeplearning, que foram treinados posteriormente.